Trabajo Práctico Lenguajes Formales y Autómatas

Alumnos: Giuliano Bianchini Broda, Nicolás Crispín Santucci, Juan Bautista Dutto

Decisiones de Diseño

El método de normalización lo que hace es transformar los nombres de las variables a *VARx*, los valores constantes a *LIT*, y los nombres de las funciones se unifican a *FUNC*. Esto garantiza que diferentes funciones con la misma estructura algorítmica, pero escritas con diferentes nombres, adopten la misma convención estándar estructural.

Definimos que el umbral de candidatas a clones es el 75% de similitud. Además consideramos que dos funciones son similares cuando superan el 50% de similitud sin superar el 75% y consideramos que no serían similares por debajo del 50%.

Métrica Elegida y Justificación

Cómo método de comparación se usó el método de Jaccard de N-gramas (con n en 3). Decidimos optar por esta métrica dado que el método de Jaccard es muy robusto a la hora de evaluar el grado de superposición entre dos conjuntos. Y si a esto, le combinamos n-gramas en lugar de comparar tokens individuales, no solo se verifica cuáles son las operaciones que existen en la función, sino que permite obtener el contexto estructural inmediato. Y optamos por un tamaño de n = 3, porque ofrece es lo suficientemente grande para retener la estructura sintáctica, pero lo bastante pequeño para tolerar variaciones menores sin que el porcentaje de similitud caiga abruptamente a 0.

Limitaciones Conocidas

Las limitaciones que encontramos en nuestra resolución son las siguientes:

- Por un lado, el reordenamiento de sentencias. Debido a que la serialización de AST respeta la posición exacta del código, si dos funciones hacen las mismas operaciones, pero cambian el orden de las sentencias independientes, las secuencias de los tokens se modifican, lo que rompe la cadena de los n-gramas y baja el porcentaje de similitud, sin importar si el resultado es el mismo.
- Otra limitación que podemos identificar es el despliegue de variables temporales, ya que si una función resuelve una ecuación en una sola línea y otra función (que sería su clon) la divide en varias líneas utilizando variables intermedias, la estructura del AST cambia muchísimo, haciendo que no pueda detectarse.
- Además, identificamos otra limitación con respecto a las funciones, y es que no distinguimos entre funciones que son síncronas de aquellas que son asíncronas.
- Y finalmente, encontramos un problema a la hora de detectar clones semánticos. Nuestra herramienta hace un análisis totalmente sintáctico, por lo que si dos funciones resuelven el mismo problema matemático, pero utilizan enfoques algorítmicos distintos (como un bucle for iterativo y una función recursiva), se van a clasificar como “No similares”, debido a la ausencia de comprensión semántica.

Posibles Mejoras

Las posibles mejoras que proponemos en nuestro proyecto, son las siguientes:

- Ordenar los términos de las operaciones conmutativas, "más cortos primero" (menor cantidad de operaciones dentro del término). Buscar romper en caso de empates salvo exacta similitud sintáctica (mismas operaciones en mismo orden de ambos términos).
- En caso de operaciones que en inicio ya estén separadas por líneas, unirlas a una sola, para posteriormente ordenarlas y volver a separarlas para que en funciones diferentes queden ordenadas de la misma manera.
- Aplanar las operaciones, de tal manera que queda una operación por renglón, ejemplo: asignador = a + b.
- Eliminar documentación de una función.